

DocViz-Agent: 다문서 질의 기반 시각화 생성을 위한 5 축 에이전트 파이프라인과 시각 사양 계약 (VSC) 기반 결정론 적 평가

연구진 (placeholder)

2026 년 6 월

Abstract

다수의 문서에 분산된 정보를 통합하여 사용자 질의에 부합하는 시각화 산출물을 생성하는 과제는 실세계 정보 처리 작업에서 핵심적이지만, 기존 연구는 단일 문서 단일 시각화 유형에 국한되어 왔다. 본 논문은 이러한 작업을 다문서 질의 기반 시각화 (Query-Grounded Multi-Document Visualization, QG-MDV) 로 정형화하고, 학계에서 검증된 일곱 개의 다문서 벤치마크로부터 표본 단위 추론 유형 표지를 보존한 300 개 다문서 묶음을 구축한다. 제안 방법 DocViz-Agent 는 다섯 개의 축—교차문서 반복 검색 (Cross-doc Iterative Search, CIS), 전략적 증거 표현 (Strategic Evidence Format, SEF), 유형 인식 다중 시각화 생성 (Type-aware Multi-Viz Generation, TMG), 출처 귀속 출력 (Source-Attributed Output, SAO), 시각 사양 계약 (Visual Specification Contract, VSC) —으로 구성된다. SEF 는 dots.mocr (3B 다국어 문서 레이아웃 파싱 모델) 의 결정론적 추출 결과를 본 연구의 결정론적 파이프라인이 직접 소비할 수 있는 구조적 표현으로 변환하며, VSC 는 시각화 도메인 특화 언어 (Domain-Specific Language, DSL) 의 형식적 계약, 위반 검증기 (validator), 일회성 보수 (repair) 루프로 구성된다. SEF 와 VSC 가 처리하는 실패 양상—형식 오류 DSL, 차원 불일치 차트, 끊어진 도식 엣지, 미지원 시각 표지, 산출물 간 증거 불일치—은 다문서 질의응답에 존재하지 않는 시각화 고유 (viz-exclusive) 양상이다. 평가는 DiagramEval 의 렌더링-시각 언어 모델 추출 기반 그래프 정렬 지표를 차트와 도식 두 계열에 통합 적용한다. 네 개 백본에 걸친 교차 실험을 통해 다문서 출처 귀속 점수가 백본 종류와 파이프라인 종류에 무관하게 일관되게 낮음을 진단적 발견으로 제시한다.

1 서론 (Introduction)

대형 언어 모델 (Large Language Model, LLM) 기반 자동 시각화 생성에 관한 최근 연구들은 단일 표 혹은 단일 텍스트로부터 차트와 도식을 생성하는 능력을 빠르게 향상시켜 왔다 [1, 2]. 그러나 실제 정보 처리 작업의 다수는 단일 문서로부터의 변환이 아니라 여러 문서에 분산된 정보를 통합한 뒤 시각화하는 형태이다. 금융 분석가는 복수의 사업보고서로부터 부문별 매출 추이를 통합 시각화 하며, 의학 연구자는 다수의 논문에서 약물 효과의 시간적 변화를 정리하고, 정책 분석가는 정부 보고서 간 정책 변화의 인과 흐름을 도식화한다. 이러한 작업은 정보 출처가 다중 문서이고, 사용자의 도가 자연어 질의로 표현되며, 출력 형식이 차트와 도식을 모두 포괄해야 한다는 점에서 기존 단일 문서 단일 유형 시각화 생성 연구가 다루지 못한 영역이다.

본 논문은 이러한 작업을 **다문서 질의 기반 시각화 (Query-Grounded Multi-Document Visualization, QG-MDV)** 로 정형화한다. 본 과제는 자연어 질의 Q 와 다문서 묶음 $\mathcal{D} = \{D_1, \dots, D_n\}$ ($n \geq 2$) 이 주어질 때, 모든 시각적 주장이 $\mathcal{D}$ 의 어느 문서 청크에 근거되고 Q 의 정보 요구를 만족하는 시각화 산출물 V 를 생성하는 것을 목표로 한다. 출력은 결정론적 도메인 특화 언어 (Domain-Specific Language, DSL) 인 Chart.js JSON 또는 Mermaid 마크다운으로 표현되며, 차트 계열 다섯 종과 도식 계열 다섯 종으로 구성된 열 가지 시각화 기본형으로 한정된다.

시각화 생성의 고유 어려움. 다문서 질의응답 (Multi-Document QA, MD-QA) 과 비교했을 때, 다문서 질의 기반 시각화는 다음 다섯 가지 실패 양상을 추가로 다루어야 한다: (i) 형식 오류 DSL, (ii) 차원 불일치 차트 (예: 레이블 수 $\neq$ 데이터 점 수), (iii) 끊어진 도식 엣지 (참조되지 않는 노드 식별자), (iv) 미지원 시각 표지, (v) 산출물 간 증거 불일치 (한 산출물의 수치가 다른 산출물의 수치와 모순). 이러한 양상은 다문서 질의응답의 평가 양식에 존재하지 않는, 시각화 생성에 고유한 (viz-exclusive) 어려움이다. 본 연구는 이러한 양상을 체계적으로 처리하기 위한 시각 사양 계약 (VSC) 을 제안한다.

기여 (Contributions). 본 연구의 기여는 다음 네 가지로 요약된다.

(C1) 일곱 개의 학계 검증 다문서 벤치마크—Loong [9], DocHop-QA [10], FinMMDocR [11], VisDoMBench [12], MultiHop-RAG [13], FinAuditing [14], TEMPO [15] —로부터 표본 단위 추론 유형 표지를 보존한 300 개 다문서 묶음을 추출한 QG-MDV 벤치마크. 모든 원문은 실제 PDF 또는 구조화 문서이며 Wikipedia 발췌는 포함되지 않는다.

(C2) 다섯 축—CIS, SEF, TMG, SAO, VSC —으로 구성된 DocViz-Agent. SEF 는 dots.mocr [17] 의 결정론적 레이아웃 + SVG 추출 결과를 시각 사양 생성에 최적화된 구조적 표현으로 변환하며, VSC 는 시각 DSL 의 형식 계약과 위반 검증기, 일회성 보수 루프로 구성된다. 시제품 측정에서 TMG 단독 절제 시 절대 점수 격차 $\Delta = -0.254$ 로 가장 컸으며, VSC 와 SEF 의 추가 절제 효과는 본 연구의 5 단계 측정으로 검증한다.

(C3) DiagramEval [8] 의 그래프 정렬 지표를 차트와 도식 두 계열에 통합 적용하는 단일 결정론적 평가. 공식 코드가 공개된 DiagramEval 만을 차용하여 자체 규칙 기반 정상화 계층을 회피한다. VSC 위반 비율 (예: M1 렌더링 실패, 차원 불일치, 끊어진 엣지) 을 보조 결정론적 지표로 보고한다.

(C4) 네 개 백본 모델에 걸친 실험을 통해 다문서 출처 귀속 점수가 백본과 파이프라인 종류에 무관하게 일관되게 낮음을 보이며, 이를 과제 본질적 병목으로 제시한다.

2 관련 연구 (Related Work)

2.1 차트 및 도식 생성

ChartLlama [1], Text2Chart31 [3], ChartMimic [2] 은 단일 표 혹은 단일 텍스트로부터 차트를 생성하는 능력을 다룬다. SciDoc2Diagrammer-MAF [4] 는 단일 학술 논문으로부터 도식 생성을 다루지만 다문서 통합은 다루지 않는다. 본 연구는 입력이 단일 문서가 아닌 다문서 묶음이라는 점, 그리고 출력의 형식 계약을 명시적으로 강제한다는 점에서 이러한 선행 연구와 구분된다.

2.2 다문서 질의응답과의 차이

HotpotQA [5], MMLongBench-Doc [6] 등 다문서 질의응답 연구는 다문서 추론과 출처 귀속을 다룬다. 본 연구는 이러한 연구로부터 문서 풀과 추론 유형 표지를 차용하되 출력 형식을 시각화로 재정의함으로써, 다문서 질의응답에 존재하지 않는 다섯 가지 시각화 고유 실패 양상 (§1) 을 평가 대상으로 추가한다. CIS, SAO 두 축은 다문서 질의응답과 메커니즘을 공유하나, SEF, TMG, VSC 세 축은 시각화 생성 특유의 양상을 다룬다.

2.3 시각화 평가

DiagramEval [8] 은 도식을 렌더링한 후 시각 언어 모델로 노드와 엣지를 추출하여 그래프로 변환하고, 노드 정렬과 경로 정렬 지표로 평가하며 사람 평가와 피어슨 상관 $r = 0.43$ 의 정합성을 보인다. 공식 코드가 저자 GitHub 저장소에 공개되어 있다. Doc2Chart [7] 는 교차 주의 가중치 기반 귀속 지표 CHARTEVAL 을 제안하나 본 연구 작성 시점 기준 공식 평가 코드가 공개되지 않았으므로 채택하지 않는다. 본 연구는 DiagramEval 의 렌더링-시각 언어 모델 추출 접근법을 차트와 도식 두 계열에 통합 적용한다.

2.4 문서 레이아웃 파싱

dots.mocr [17] 는 3B 파라미터의 다국어 문서 파싱 시각 언어 모델로, 페이지의 모든 레이아웃 요소 (제목, 본문, 표, 그림, 캡션 등) 의 경계 상자와 의미 범주, 그리고 각 요소의 텍스트 (표는 HTML, 수식은 LaTeX, 나머지는 마크다운) 를 단일 호출로 산출한다. 변형 모델 dots.mocr-svg 는 차트와 그림을 SVG 코드로 직접 추출한다. 본 연구는 이러한 결정론적 추출 결과를 출발점으로 SEF (§4.2) 를 구성한다. 본 연구는 dots.mocr 자체의 추출 성능을 측정하지 않으며, 그 출력을 시각화 생성 파이프라인의 결정론적 입력 표현으로 활용한다.

3 QG-MDV 과제 정형화 (Task Formalization)

3.1 정의

QG-MDV 과제의 입력은 자연어 질의 Q 와 다문서 묶음 $\mathcal{D} = \{D_1, \dots, D_n\}$ ($n \geq 2$) 이며, 출력은 시각화 산출물 집합 $V = \{V_1, \dots, V_k\}$ ($1 \leq k \leq 3$) 이다. 각 V_j 는 결정론적 DSL (Chart.js JSON 또는 Mermaid 마크다운) 로 표현된다. V 는 다음 네 조건을 모두 충족해야 한다: 모든 시각적 요소가 $\mathcal{D}$ 의 특정 문서 청크에 근거, Q 의 정보 요구를 만족, 정보 구조에 적합한 시각화 유형 선택, 그리고 각 V_j 가 형식 제약 (§4.5) 을 충족.

3.2 두 가지 직교 분류 축

각 질의는 두 개의 독립적인 분류 축으로 표현된다. 추론 난이도 (challenge type) 축은 다섯 가지이다: 다단계 추론 (multi-hop), 산출물 계획 (artifact planning), 혼합 산출물 (mixed artifact), 방해 문서 다수 (distractor-heavy), 모순 해소 (contradiction). 출력 구조 (output type) 축도 다섯 가지이다: 수치형, 관계형, 시간형, 계층형, 비교형. 두 축은 독립적이다.

3.3 시각화 기본형

출력 DSL 은 열 가지 기본형으로 한정된다. 차트 계열: chartjs_bar, chartjs_line, chartjs_grouped_bar, chartjs_pie, chartjs_scatter. 도식 계열: mermaid_flowchart, mermaid_timeline, mermaid_mindmap, mermaid_sequenceDiagram, mermaid_classDiagram. 두 DSL 은 모두 공개 표준이며 LLM 이 사전 학습 단계에서 학습한 형식이다.

4 DocViz-Agent 방법 (Method)

DocViz-Agent 는 다섯 개의 축으로 구성된다. 처리 순서는 다음과 같다: 원문 PDF 가 dots.mocr 결정론적 전처리를 거쳐 SEF 로 변환되고, CIS 가 질의에 적합한 SEF 블록을 검색하며, TMG 가 검색된 블록의 구조에 적합한 시각화 유형을 결정하고, 시각 사양 (visual spec) 이 생성된 후 결정론적으로 DSL 로 변환되며, VSC 위반 검증기가 형식 제약 충족을 확인하고 위반 시 일회성 보수가 적용되며, SAO 메타데이터가 각 시각 요소에 부착된다.

4.1 교차문서 반복 검색 (Cross-doc Iterative Search, CIS)

CIS 는 질의 Q 로부터 시작하여 SEF 블록 인덱스에서 후보 블록을 검색하고, 검색된 블록이 다른 블록을 참조하는 경우 (SEF 의 cross_refs 필드 활용) 그 참조 블록을 추가 검색한다. 충분성 (sufficiency) 자체 평가를 통과할 때까지 반복하며, 최대 반복 횟수는 사전 결정된다. 단일 시도 검색이 아닌 반복 검색을 채택함으로써 가교 개체 (bridge entity) 를 따라가는 다문서 통합이 가능하다.

4.2 전략적 증거 표현 (Strategic Evidence Format, SEF)

원리. SEF 는 원문 문서의 결정론적 표현으로서, 시각 사양 생성에 최적화된 구조적 정보를 사전 산출한다. dots.mocr 이 산출한 페이지별 JSON (블록 경계 상자, 의미 범주, 텍스트) 을 출발점으로, 각 블록에 결정론적으로 다음 필드를 추가한다: (a) **청구 단위 (claim_units)** —텍스트 블록 내 수치 주장 단위의 분해. 각 단위는 청구 텍스트, 청구 유형 (수치, 추세, 순위 등), 정규화된 개체, 정규화된 값과 단위, 시간 정박. (b) **그림 메타데이터**—Picture 범주 블록의 경우 dots.mocr-svg 가 산출한 SVG 코드, 시각 유형 분류, 추출된 데이터 표. (c) **표 파싱 결과**—Table 범주 블록의 경우 HTML 을 결정론적으로 행렬로 파싱한 결과. (d) **교차 참조 (cross_refs)** —그림이 본문의 어떤 데이터를 시각화하는지 등의 관계. (e) **시각화 가능 색인 (viz_affordance_index)** —출력 구조 유형 (수치형, 관계형 등) 별 후보 블록 식별자 목록.

B6 전용성과 공정성. SEF 는 B6 (제안 방법) 만 입력으로 받는다. 비교 대상 (B1-B5, B7) 은 dots.mocr 이 산출하는 표준 마크다운 (*_nohf.md) 을 입력으로 받으며, 이는 dots.mocr 의 기본 출력 그대로 별도 가공이 없다. 두 입력의 정보 원천은 동일하며 (동일한 원문 PDF), 표현 형식만 다르다. SEF 는 본 연구의 방법 기여이며, “비교 대상이 SEF 를 활용하지 못하는 것” 은 비교 대상의 한계이지 불공정이 아니다 (§6.2 참고).

생성 비용. SEF 생성은 LLM 호출 없이 dots.mocr 추출 + 규칙 기반 변환만으로 수행된다. dots.mocr 자체는 3B 모델로 본 연구의 GPU 인프라에서 로컬 추론된다 (API 비용 없음). SEF 변환 규칙은 부록에 명시된다.

4.3 유형 인식 다중 시각화 생성 (Type-aware Multi-Viz Generation, TMG)

TMG 는 CIS 가 검색한 SEF 블록과 질의 Q 를 입력으로 받아 다음을 결정한다: (i) 시각화 산출물의 수 ($k = 1, 2, 3$), (ii) 각 산출물의 viz_type (열 가지 기본형 중), (iii) 각 산출물에 매핑되는 SEF 블록 분할. 약한 사전 매핑 (수치형 → 차트, 관계형 → 도식 등) 이 안내로 제공되나 강제 라우터는 아니다. 시제품 측정에서 TMG 단독 절제 시 절대 점수 격차가 $\Delta = -0.254$ 로 가장 컸으며, 이는 다 문서 시각화의 본질적 어려움이 정보 추출 자체가 아닌 정보 구조에 적합한 시각화 형식 선택에 있음을 시사한다.

4.4 출처 귀속 출력 (Source-Attributed Output, SAO)

SAO 는 생성된 시각 사양의 각 시각적 요소 (노드, 엣지, 데이터 점) 에 SEF 블록 식별자와 청구 단위 식별자를 메타데이터로 부착한다. 형식은 {doc_id}#{bid}#{cuid} 로 통일된다. SAO 메타데이터는 VSC 위반 검증기 (§4.5) 의 입력으로도 사용된다 (시각 요소가 참조하는 SEF 식별자가 실제로 SEF 에 존재하는지 확인).

4.5 시각 사양 계약 (Visual Specification Contract, VSC)

VSC 는 세 개의 결정론적 구성 요소이다.

(a) **정형 시각 사양 (Canonical Visual Spec).** TMG 가 자유 형식 DSL 을 직접 생성하는 대신, 우선 정형 사양을 생성한다. 차트의 경우 사양은 viz_type, 축 정의, 시리즈 정의, 각 데이터 점의 (시리즈, 범주, 값, 단위, 출처 SEF 식별자) 를 포함한다. 도식의 경우 사양은 viz_type, 노드 집합 (각각 식별자와 라벨), 엣지 집합 (각각 출발 노드, 도착 노드, 관계 라벨, 출처 SEF 식별자) 을 포함한다. 정형 사양은 부록에 JSON 스키마로 명세된다.

(b) **결정론적 사양 → DSL 변환.** 정형 사양으로부터 Chart.js JSON 또는 Mermaid 마크다운으로의 변환은 LLM 호출 없이 규칙 기반으로 수행된다. 이로써 “사양은 올바르나 DSL 변환에서 형식 오류 발생” 의 양상이 차단된다.

(c) **위반 검증기 (Validator) + 일회성 보수 루프.** 검증기는 다음 양상을 결정론적으로 검사한다: (i) DSL 이 렌더링 가능한지 (M1 렌더 성공), (ii) 차원 정합 (Chart.js 의 labels.length =

각 `datasets[i].data.length`), (iii) 엣지 노드 참조 유효성 (Mermaid 에서 모든 엣지의 양 끝 노드가 노드 집합에 존재), (iv) 시각 표지 지원 여부 (열 가지 기본형 한정 충족), (v) 출처 SEF 식별자 유효성 (모든 출처 참조가 SEF 에 존재). 위반 발견 시 위반 유형과 위치를 명시한 보수 프롬프트가 TMG 에게 한 차례 전달되며, 보수 실패 시 $M1 = 0$ 으로 계상된다.

VSC 가 처리하는 다섯 양상은 모두 다문서 질의응답에 존재하지 않는 시각화 고유 양상이다. 이것이 본 연구가 “QG-MDV 는 MD-QA 의 출력 형식 변경에 불과한 과제가 아니다” 라는 주장을 뒷받침하는 경험적 근거이다 (§9 참고).

5 평가 프레임워크 (Evaluation Framework)

5.1 설계 원칙

본 연구의 평가는 자체 규칙 기반 정상화 계층을 회피한다. 시제품 단계에서 자체 정확 일치 셀 F1 과 자체 정규식 기반 Mermaid 파서를 도입한 결과 모든 비교 대상의 점수가 97% 영점에 수렴하는 바닥 상태가 관찰되었으며, 이는 자체 구현된 규칙 기반 평가가 다양한 출력 형식 변이를 일관되게 처리하지 못함을 시사하였다. 본 연구는 공식 코드가 공개된 DiagramEval 만을 평가 차용하여 선행 연구의 사람 정합성 검증을 인정받는다.

VSC 위반 검증기 (§4.5) 는 평가 프레임워크의 일부가 아니며 생성 파이프라인의 일부이다. 즉 VSC 는 B6 산출물의 품질을 결정론적으로 보장하기 위한 메커니즘이며, 모든 비교 대상의 산출물은 동일한 DiagramEval 평가를 받는다.

5.2 통합 결정론적 평가

DiagramEval 절차: 산출물 PNG 렌더링 → 시각 언어 모델이 시각 요소 추출 → 노드 정렬 F1 + 경로 정렬 F1 계산. 의미적 임계값 (sentence-transformer 코사인 유사도 0.75) 기반 노드 매칭. 원논문 사람 정합성 $r = 0.43$ (CLIPScore 대비 약 4 배).

시각 언어 모델 선택. 원논문은 Gemini-2.0-Flash-lite 사용. 본 연구는 두 후보—Qwen3.5-397B 의 시각 변형 (로컬, 비용 0) 및 GPT-5-mini 시각 (배치 API) —을 30 개 표본 사람 점검으로 비교한 후 단일 모델을 채택하며, 선택된 모델이 모든 단계에 일관 적용된다.

5.3 보조 지표

Evidence F1. B6 는 SAO 메타데이터로 `evidence_ids` 를 명시적으로 생성하므로 집합 기반 F1 을 계산한다. 비교 대상은 시각화 텍스트와 원문 청크 간 임베딩 코사인 유사도 0.75 이상을 매칭으로 간주하는 암묵적 매칭을 적용한다. 두 방식은 별도 열로 보고된다.

Intent Coverage. 헝가리안 매칭으로 산출물을 골드 의도에 매칭한 후 ROUGE-L 기반 매칭 비율 계산.

VSC 위반 비율 (보조 결정론적 지표). M1 렌더링 성공률, 차원 정합 비율, 엣지 노드 참조 유효 비율, 출처 참조 유효 비율. VSC 가 처리하는 다섯 양상의 정량적 빈도이며, 시각화 고유 어려움의 존재를 보이는 일관성 있는 결정론적 지표이다.

이미지 단계. M5 CLIPScore (OpenCLIP ViT-L/14 로컬). A5 시각 리커트 (Claude Sonnet 4.6 비전, Anthropic 배치 API 100 개 부집합).

5.4 엄격 게이트

B6 가 노드 F1, 경로 F1, Evidence F1, Intent Coverage 네 지표 모두에서 가장 강한 비교 대상 대비 +0.020 이상의 차이를 보일 때 강 신호로 판정한다. 가중치 합산 점수는 사용하지 않는다.

6 실험 설정 (Experimental Setup)

6.1 원문 전처리—dots.mocr 사용 지침

본 연구의 모든 단일 PDF 출처는 dots.mocr 으로 전처리된다 (Loong 은 ModelScope 마크다운 사용으로 제외). 전처리 산출물은 두 가지이다: (i) 비교 대상 입력용 표준 마크다운, (ii) B6 입력용 SEF.

호출 절차 (이미 운영 중인 vLLM 서버를 사용). 페이지별 호출에 `prompt_layout_all_en` 프롬프트 모드를 사용한다. 그림 영역 추가 SVG 추출에는 `prompt_image_to_svg` 프롬프트 모드와 `dots.mocr-svg` 변형 모델을 사용한다. `prompt_layout_only_en` (탐지만), `prompt_ocr` (텍스트만), `prompt_web_parsing`, `prompt_scene_spotting` 모드는 본 연구에서 사용하지 않는다.

출력 처리. dots.mocr 의 페이지별 JSON 은 모든 레이아웃 요소를 다음 범주 중 하나로 분류한다: Caption, Footnote, Formula, List-item, Page-footer, Page-header, Picture, Section-header, Table, Text, Title. 텍스트 형식은 그림 (생략), 수식 (LaTeX), 표 (HTML), 나머지 (마크다운) 로 결정된다.

비교 대상용 표준 마크다운 (*_nohf.md). dots.mocr 의 기본 출력에 페이지 머리/꼬리만 제거된 형태로, 추가 가공 없이 비교 대상에게 그대로 전달된다.

B6 용 SEF 생성. dots.mocr JSON 을 입력으로 받아 SEF (JSON) 산출. 청구 단위 분해는 spaCy NER + 정규식 (수치, 시간, 단위 패턴) 으로 수행. 그림 블록은 dots.mocr-svg 로 SVG 추출 후 SVG 품질 검사 (well-formedness, viewBox 존재) 통과 시 `safe_to_use_numerics=true`, 실패 시 SVG 코드만 보존하고 데이터 표는 비움. 표 블록은 lxml 로 HTML → 행렬 변환. 교차 참조는 본문의 “Figure N” / “Table N” 명시 인용을 정규식으로 매핑. SEF JSON 스키마는 부록 A 에 명시된다.

SEF 생성 실패 시 대체. dots.mocr 이 페이지 파싱 실패 시 PyMuPDF 텍스트 추출로 대체하며, SEF 의 그림/표 메타데이터를 비우고 `extraction_quality=fallback` 으로 표시한다. 대체된 표본 비율은 한계 (§9) 에 보고된다.

6.2 백본 모델

네 백본: 오픈 프론티어 Qwen3.5-397B-A17B-FP8 (시제품 강 신호 충족), 오픈 전문가 혼합 DeepSeek-V4-Flash, 클로즈드 저비용 GPT-5-mini, 클로즈드 프론티어 Claude Opus 4.8. 등급 분산 (오픈/클로즈드 × 저비용/프론티어) 으로 단일 모델군 의존 회피.

난이도 필터링과 골드 추출 모델은 평가 풀과 분리: GPT-5 완전판 + Claude Opus 4.7 다수결. 두 모델 모두 평가 풀 미포함으로 순환 평가 위험 차단.

6.3 말뭉치 구성

300 개 다문서 묶음. 추론 난이도 유형별 60 개. 각 유형의 60 개를 서로 다른 세 출처에 균등 분산 (단일 출처 의존 차단).

6.4 질의 생성 파이프라인

세 단계: 압축 문서 표현 (Loong 절차 차용), 과제별 프롬프트와 출력 유형 휴리스틱 (25 개 템플릿), 자기 평가 관문 (Text2Chart31 메커니즘). **중요:** 질의 생성은 dots.mocr 표준 마크다운만을 입력으로 사용하며, SEF 전용 정보 (예: `safe_to_use_numerics`, `cross_refs`) 는 질의에 누출되지 않는다. 이로써 “B6 만 답할 수 있는 질의” 가 생성되지 않음을 보장한다. 비용 약 0.96 달러 + Prolific 자연스러움 점검 30 표본 30 달러.

난이도 필터링: GPT-5 완전판과 Claude Opus 4.7 의 다수결. 두 모델 모두 통과 시 제거 (너무 쉬움), 두 모델 모두 실패하는 100 개를 엄격 표본, 한 모델만 실패하는 200 개를 완화 표본으로 구성하여 총 300 개 확보.

추론 난이도 유형	60 개 표본 출처 (20+20+20 분산)	합계
다단계 추론	Loong 연쇄 추론 (20) + DocHop-QA 다단계 추론 개념 (20) + MultiHop-RAG 추론 질의 (20)	60
산출물 계획	Loong 군집화 (20) + DocHop-QA 종합 (20) + FinMMDocR 다단계 계산 (20)	60
혼합 산출물	VisDoMBench SciGraphQA (20) + VisDoMBench PaperTab/FeTaTab (20) + FinMMDocR 포트폴리오 시나리오 (20)	60
방해 문서 다수	MultiHop-RAG 영 답 질의 (20) + FinMMDocR 폐이지 횡단 (20) + Loong 장문맥 방해 변이 (20)	60
모순 해소	FinAuditing 일관성 (20) + TEMPO 시점 횡단 (20) + DocHop-QA 모순 개념 (20)	60
합계	일곱 개 출처 벤치마크	300

Table 1: 추론 난이도 유형별 출처 벤치마크 구성.

6.5 골드 부집합 사람 검증

300 개 중 90 개 부집합 (추론 난이도 유형별 15, 도메인 상한 6). 다중 LLM 합집합 추출 (GPT-5-mini + Claude Opus 4.8 독립 + 합집합) → Prolific 세 평가자 × 90 표본 출처 정확성 (이진, 2/3 동의 보존) + 완전성 (누락 사실 추가, 네 번째 평가자 재검증).

6.6 비교 대상과 공정성

본 연구의 공정성 원칙은 다음 세 가지 구분에 기반한다. 첫째, 모든 비교 대상이 동일한 원문 *PDF*에 접근한다 (정보 동등성). 둘째, 각 비교 대상은 자신의 방법이 원래 가정한 입력 형식을 받는다 (방법 보존성). 셋째, 본 연구의 방법 기여인 SEF 는 B6 에만 전달되며, 이는 “B6 의 방법이 SEF 를 활용한다” 는 사실의 직접 귀결이지 추가적 이점이 아니다 (방법 기여의 정당성).

이 원칙에 따라 비교 대상은 dots.mocr 표준 마크다운 (*_nohf.md) 을 입력으로 받으며—이 마크다운은 본 연구가 추가 가공하지 않은 dots.mocr 표준 출력이다—각자의 원래 입력 형식 가정에 따라 처리한다 (예: B1 MatPlotAgent 는 plain text 가정, B2 NVAGENT 는 pseudo-table 가정, B3 CoDA 는 텍스트 데이터셋 가정).

식별자	명칭	입력 형식
B1	MatPlotAgent 적응판	dots.mocr 표준 마크다운
B2	NVAGENT 적응판	dots.mocr 표준 마크다운 (HTML 표 포함)
B3	CoDA 적응판	dots.mocr 표준 마크다운
B4	ViviDoc 양식	dots.mocr 표준 마크다운
B5	Direct LLM	dots.mocr 표준 마크다운 (다문서 연결)
B7	SelfRefine	dots.mocr 표준 마크다운, 자기 개선 반복
B6	DocViz-Agent (제안)	SEF JSON (CIS+SEF+TMG+SAO+VSC)

Table 2: 비교 대상 라인업과 입력 형식. SEF 는 본 연구의 방법 기여이며 B6 에 한정 적용된다.

외부 보류 평가: Text2Vis (일반 차트), Doc2Chart (의도 기반 차트), SciDoc2DiagramBench (도식). 각각의 전문가 모델이 강한 비교 기준점.

7 결과 (Results)

5 단계 측정 완료 시 채워질 위치를 빈 칸으로 표시. 시드 42, 43, 44 3 시드 평균과 표준편차 보고.

7.1 교차 과제 일반화

비교 대상	QG-MDV				Text2Vis				Doc2Chart				SciDoc2DiagramBench			
	노드	경로	출처	의도	노드	경로	출처	의도	노드	경로	출처	의도	노드	경로	출처	의도
B1 MatPlotAgent	—	—	—	—	—	—	—	—	—	—	—	—	—	—	—	—
B2 NVAGENT	—	—	—	—	—	—	—	—	—	—	—	—	—	—	—	—
B3 CoDA	—	—	—	—	—	—	—	—	—	—	—	—	—	—	—	—
B4 Vividoc	—	—	—	—	—	—	—	—	—	—	—	—	—	—	—	—
B5 Direct LLM	—	—	—	—	—	—	—	—	—	—	—	—	—	—	—	—
B7 SelfRefine	—	—	—	—	—	—	—	—	—	—	—	—	—	—	—	—
B6 DocViz-Agent	—	—	—	—	—	—	—	—	—	—	—	—	—	—	—	—

Table 3: 교차 과제 일반화. 노드 = DiagramEval 노드 F1, 경로 = DiagramEval 경로 F1, 출처 = Evidence F1, 의도 = Intent Coverage. 네 백본 평균.

7.2 추론 난이도별 분해

추론 난이도 유형	표본 수	노드/경로/출처/의도 (B6)	(강한 비교 대상)	Δ	유형별 신호
다단계 추론	60	—	—	+ _—	교차 문서 증거 재현율
산출물 계획	60	—	—	+ _—	산출물 수 정합성
혼합 산출물	60	—	—	+ _—	양태 적용 범위
방해 문서 다수	60	—	—	+ _—	방해 문서 오염 (낮을수록 우수)
모순 해소	60	—	—	+ _—	모순 적용 범위
전체	300	—	—	+ _—	—

Table 4: 추론 난이도별 결과. 네 백본 평균.

7.3 백본 횡단—진단적 발견

백본	B1	B2	B3	B4	B5	B7	B6	Δ
Qwen3.5-397B	—	—	—	—	—	—	—	+ _—
DeepSeek-V4-Flash	—	—	—	—	—	—	—	+ _—
GPT-5-mini	—	—	—	—	—	—	—	+ _—
Claude Opus 4.8	—	—	—	—	—	—	—	+ _—
백본 평균	—	—	—	—	—	—	—	+ _—

Table 5: 백본 횡단 출처 귀속 점수. 네 백본 모두에서 출처 귀속이 다른 지표보다 낮으면 다문서 출처 귀속 격차의 백본 무관 일관성 입증.

비교 대상	M1 렌더 실패%	차원 불일치%	끊긴 엣지%	미지원 표지%	출처 무효%
B1 MatPlotAgent	—	—	—	—	—
B5 Direct LLM	—	—	—	—	—
B7 SelfRefine	—	—	—	—	—
B6 (VSC 적용 후)	—	—	—	—	—
B6 -VSC (보수 루프 없음)	—	—	—	—	—

Table 6: VSC 위반 비율. 다섯 양상은 다문서 질의응답에 존재하지 않는 시각화 고유 양상이다. B6 vs B6 -VSC 비교가 VSC 의 직접 효과 정량화.

7.4 VSC 위반 비율 (시각화 고유 양상의 정량적 증거)

8 절제 분석 (Ablation Studies)

8.1 5 축 절제

변이	노드	경로	출처	의도	Δ vs 완전판
B6 완전판 (CIS + SEF + TMG + SAO + VSC)	—	—	—	—	—
B6 -CIS (단일 시도 검색)	—	—	—	—	—
B6 -SEF (B6 에 표준 마크다운만 입력)	—	—	—	—	—
B6 -TMG (시각 유형 무작위)	—	—	—	—	— (시제품 $\Delta = -0.254$)
B6 -SAO (출처 메타데이터 없음)	—	—	—	—	—
B6 -VSC (보수 루프 없음, 직접 DSL 생성)	—	—	—	—	—
B6 전체 제거 ($\approx$ B5)	—	—	—	—	—

Table 7: 5 축 절제. -SEF 변이는 B6 파이프라인을 표준 마크다운 입력으로 돌려 SEF 표현 가치를 직접 측정. -VSC 변이는 형식 제약 효과를 직접 측정.

8.2 이미지 단계 평가

비교 대상	M1 렌더링%	M5 CLIPScore	A5 가독성	A5 배치	A5 전체
B1 MatPlotAgent	—	—	—	—	—
B2 NVAGENT	—	—	—	—	—
B3 CoDA	—	—	—	—	—
B4 Vividoc	—	—	—	—	—
B5 Direct LLM	—	—	—	—	—
B7 SelfRefine	—	—	—	—	—
B6 DocViz-Agent	—	—	—	—	—

Table 8: 이미지 단계 평가. 100 개 부집합 $\times$ 일곱 비교 대상 $\times$ 네 백본. A5 는 Claude Sonnet 4.6 비전 (배치 API) 리커트.

검증 단계	지표 / 기준	측정값	통과
L2 사람 정합성	스피어만 상관 (30 시각화 점검) ≥ 0.4 (DiagramEval 발표 0.43 범위)	—	☐
L4 역방향 질의응답	B6 vs 가장 강한 비교 대상 정확도 격차 양의 방향	+ _ %p	☐
L6 외부 보류 평가	전문가 대비 $-\Delta \leq 7\%p$ (세 외부 벤치마크)	— %p	☐

Table 9: 평가 정합성 검증 표.

9 검증 (Validation)

10 논의 및 한계 (Discussion and Limitations)

MD-QA 와의 구분. CIS 와 SAO 두 축은 다문서 질의응답과 메커니즘을 공유한다. 그러나 SEF, TMG, VSC 세 축은 다문서 질의응답에 존재하지 않는 양상을 다룬다. SEF 는 시각 사양 생성에 최적화된 표현 (수치 정규화, SVG 추출, 시각화 가능 색인) 을 다루며, 질의응답의 평문 증거 추출 표현과 구조가 다르다. TMG 는 “열 가지 시각화 기본형 중 어느 것이 정보 구조에 적합한가” 라는 결정을 다루며, 질의응답에는 이러한 결정이 존재하지 않는다. VSC 가 처리하는 다섯 양상—형식 오류 DSL, 차원 불일치, 끊어진 엷지, 미지원 표지, 출처 참조 무효—은 질의응답의 평문 답에서 발생할 수 없다. 표 6의 VSC 위반 비율은 이러한 양상이 실제로 빈번하게 발생함을 정량적으로 보이는 결정론적 증거이다.

한계. (i) 도메인 범위는 의료, 금융, 법률, 학술, 뉴스, 시계열에 중심. (ii) 실제 PDF 만 사용 (Wikipedia 배제). (iii) 출력 DSL 이 Chart.js 와 Mermaid 로 한정. SciDoc2DiagramBench 보류 평가는 이미지 단계 지표만 적용. (iv) 자체 정상화 계층 회피. (v) 사람 검증 범위 제한 (30 자연스러움, 90 골드, 50 시각화 교차). (vi) Doc2Chart CHARTEVAL 미사용 (공식 평가 코드 미공개). (vii) DiagramEval 시각 언어 모델은 Qwen3.5-397B-VL 또는 GPT-5-mini 비전으로 대체 (사람 정합성 별도 점검). (viii) dots.mocr 추출 실패율 (PyMuPDF 대체 비율) 이 보고된다. (ix) VSC 의 보수 루프가 한 차례로 제한되어 일부 산출물은 보수 실패 후 M1=0 처리된다.

11 결론 (Conclusion)

본 논문은 QG-MDV 과제를 정형화하고 일곱 출처 벤치마크에서 추출한 300 다문서 묶음을 제시한다. DocViz-Agent 는 다섯 축—CIS, SEF, TMG, SAO, VSC —으로 구성되며, SEF 는 dots.mocr 의 결정론적 추출을 시각 사양 생성에 최적화된 표현으로 변환하고 VSC 는 시각화 고유의 다섯 실패 양상을 결정론적으로 처리한다. 평가는 DiagramEval 통합 적용 + VSC 위반 비율 보조 지표. 네 백 본 측정을 통해 다문서 출처 귀속 격차의 백본 무관 일관성을 진단적 발견으로 제시한다.

References

- [1] Han et al. ChartLlama: A multimodal LLM for chart understanding and generation. arXiv preprint arXiv:2311.16483, 2023.
- [2] Yang et al. ChartMimic: Evaluating LMM’s cross-modal reasoning capability via chart-to-code generation. ICLR 2025.
- [3] Zadeh et al. Text2Chart31: Instruction tuning for chart generation with automatic feedback. EMNLP 2024 Main Oral.
- [4] Mondal et al. SciDoc2Diagrammer-MAF: Towards generation of scientific diagrams from documents guided by multi-aspect feedback refinement. Findings of EMNLP 2024.

- [5] Yang et al. HotpotQA: A dataset for diverse, explainable multi-hop question answering. EMNLP 2018.
- [6] Ma et al. MMLongBench-Doc: Benchmarking long-context document understanding with visualizations. NeurIPS 2024 Datasets and Benchmarks Track.
- [7] Jain et al. Doc2Chart: Intent-driven zero-shot chart generation from documents. EMNLP 2025 Main.
- [8] Liang and You. DiagramEval: Evaluating LLM-generated diagrams via graphs. EMNLP 2025 Main.
- [9] Wang et al. Leave no document behind: Benchmarking long-context LLMs with extended multi-doc QA. EMNLP 2024 Oral.
- [10] Xiao et al. DocHop-QA: Towards multi-hop reasoning over multimodal document collections. arXiv preprint arXiv:2508.15851, 2025.
- [11] FinMMDocR: Benchmarking financial multimodal reasoning. AAAI 2026.
- [12] Suri et al. VisDoM: Multi-document QA with visually rich elements using multimodal retrieval-augmented generation. NAACL 2025.
- [13] Tang and Yang. MultiHop-RAG: Benchmarking retrieval-augmented generation for multi-hop queries. arXiv preprint arXiv:2401.15391, 2024.
- [14] Wang et al. FinAuditing: A financial taxonomy-structured multi-document benchmark for evaluating LLMs. arXiv preprint arXiv:2510.08886, 2025.
- [15] TEMPO: A realistic multi-domain benchmark for temporal reasoning-intensive retrieval. arXiv preprint arXiv:2601.09523, 2026.
- [16] Wang et al. Text2Vis: A challenging and diverse benchmark for generating multimodal visualizations from text. arXiv preprint arXiv:2507.19969, 2025.
- [17] Zheng et al. Multimodal OCR: Parse anything from documents. arXiv preprint arXiv:2603.13032, 2026.

A SEF JSON 스키마 (요약)

SEF (Strategic Evidence Format) 스키마

```
{
  "doc_id": str, "source_format": "dots.mocr_v1.0",
  "doc_meta": { "title", "page_count", "domain", "language" },
  "blocks": [{
    "bid": str, "page": int, "bbox": [x1,y1,x2,y2],
    "category": "Text|Title|Section-header|Picture|Table|Caption|
                Formula|Footnote|List-item|Page-header|Page-footer",
    "reading_order": int,
    "text_md": str (Text/Title 등),
    "text_html": str (Table 만),
    "claim_units": [{
      "cuid": str, "claim_text": str,
      "claim_type": "numeric_value|numeric_trend|ranking|
                    categorical|temporal_event|...",
      "entities": [{"surface", "canonical", "type"}],
      "values": [{"raw", "normalized_value", "unit"}],
      "time_anchors": [{"raw", "normalized"}],
      "section_path": str
    }],
    "picture_meta": { # Picture 범주만
      "caption_bid", "svg_code", "svg_quality_score",
      "visual_type", "chart_subtype_inferred",
      "extracted_data_table": [{"category","series","value","unit"}],
      "safe_to_use_numerics": bool
    },
    "table_parsed": { # Table 범주만
      "headers", "rows", "units"
    }
  }],
  "cross_refs": [{"from_bid", "to_bid", "rel"}],
  "viz_affordance_index": {
    "numeric_trend": [bid|cuid], "categorical_comparison": [...],
    "ranking": [...], "part_to_whole": [...], "correlation": [...],
    "hierarchical_structure": [...], "process_flow": [...],
    "temporal_event": [...], "causal_chain": [...]
  },
  "extraction_quality": "full|partial|fallback"
}
```

B VSC 위반 검증기 규칙

VSC 검증 규칙

규칙 R1 (M1 렌더 성공):

Chart.js → puppeteer 헤드리스 렌더 무오류.
Mermaid → mermaid-cli 무오류.

규칙 R2 (차원 정합 — Chart.js만):

`spec.labels.length == spec.datasets[i].data.length` for all `i`.

규칙 R3 (엣지 노드 참조 — Mermaid 도식만):

모든 `edge.from`, `edge.to` `spec.node_ids`.

규칙 R4 (지원 표지):

`viz_type` 열 가지 기본형 집합.

규칙 R5 (출처 참조 유효):

모든 `element.source_eids` 가 `SEF.blocks[*].bid`
또는 `SEF.blocks[*].claim_units[*].cuid` 에 존재.

위반 시 보수 프롬프트:

"{viz_type} 시각 사양에서 다음 위반 발견: {위반 유형}

위치: {element_id}, 상세: {detail}.

SEF 증거 사실만 사용하여 한 차례 보수하라."

보수 후 재검증. 재검증 실패 시 `M1=0`.